



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Relación entre la Educación y el Desarrollo Productivo en Argentina

Laboratorio de Datos - Trabajo Práctico 01

2do. Cuatrimestre - 2025

Departamento de Computación, FCEyN, UBA

Soriano Félix, Glionna Sofía, Gantman Ramiro

Nombre del grupo: Recursantes_FC

El presente trabajo busca responder si en Argentina existe una relación entre la presencia de establecimientos educativos, y el desarrollo de actividades productivas, para determinar si la educación está relacionada con el desarrollo productivo de la república. Para ello se procesaron y limpiaron datos de acceso público correspondientes al año 2022 para su posterior análisis. Los datos ya depurados fueron graficados mediante herramientas de visualización. Se concluyó que, si bien existe una relación entre establecimientos educativos y empleo, esta parece ser inversa si se mide de forma porcentual respecto a la población.

1. Introducción

El presente trabajo tiene como objetivo responder a la pregunta de si en la República Argentina existe una relación entre la presencia de establecimientos educativos y el desarrollo de actividades productivas. Para ello, se recurrió al análisis y limpieza de distintas tablas de datos de acceso público del año 2022.

Se emplearon tres fuentes de datos: la tabla de [“Padrón Oficial de Establecimientos Educativos”](#) correspondiente al año 2022, proveniente del portal oficial del Estado argentino; la tabla de [“Datos de establecimientos por departamento, actividad y género”](#), obtenida del Ministerio de Economía; y la tabla de [“Padrón Poblacional”](#), proporcionada por el INDEC. En adelante, se hará referencia a ellas como las “tablas originales” o “datasets”.

Se llevó a cabo un análisis de calidad de las tablas originales de Establecimientos Educativos y Establecimientos Productivos, con el fin de identificar su estructura y determinar en qué forma normal se encontraban. Este paso fue fundamental para detectar posibles problemas de redundancia, inconsistencia o dependencias funcionales, que pudieran afectar la precisión de los análisis posteriores. Como resultado, se identificó al menos un problema de calidad en cada una de las tablas, y se elaboraron métricas GQM (Goal-Question-Metric) que permitieron cuantificar la gravedad de cada problemática.

Posteriormente, se graficó en la herramienta de edición visual colaborativa *MIRO*, un Diagrama de Entidad-Relación (DER) que permitió modelar de manera conceptual los datos necesarios para resolver los problemas planteados con los datos provenientes de las tablas originales y se definieron los esquemas correspondientes al DER en 3FN.

Una vez completada la limpieza y depuración de los datos, se procedió a un análisis mediante consultas SQL integradas en el lenguaje de programación Python, con el objetivo de explorar la posible relación entre las actividades productivas y la presencia de establecimientos educativos. Finalmente, los resultados obtenidos fueron representados gráficamente mediante la biblioteca Matplotlib, lo que permitió visualizar las tendencias y facilitar su interpretación.

2. Procesamiento de Datos

2.1 Formas Normales

Se analizó la forma normal de las siguientes tablas originales: “Padrón Oficial de Establecimientos Educativos” (EE), “Datos de establecimientos por departamento, actividad y género” (EP), la tabla agregada “Actividades” y “Padrón poblacional” (en esta el departamento se tomará como una columna más para el análisis de la forma normal) con el objetivo de

mejorar el diseño de estas bases para lograr responder de forma eficiente la pregunta del trabajo.

Primera Forma Normal (1FN):

Todas las tablas se encuentran en 1FN, ya que todos sus atributos son atómicos y representan distintos tipos de datos.

Segunda Forma Normal (2FN):

La tabla de EE cumple la 2FN, dado que no posee claves compuestas (la clave primaria es "CUEANEXO"), lo que impide la existencia de dependencias parciales, y además se encuentra en 1FN.

La tabla de EP no cumple con la 2FN, ya que utiliza una clave compuesta PK = (anio, in_departamentos, clae6, género) y existen atributos que dependen solo de una parte de dicha clave. Los atributos que no respetan la 2FN son los siguientes:

- **departamento** depende de **in_departamentos**
- **provincia_id** depende de **in_departamentos**
- **provincia** depende de **in_departamentos**
- **clae2** depende de **clae6**
- **letra** depende de **clae6**

Tercera Forma Normal (3FN):

Por último, como la tabla EP no cumple 2FN, tampoco cumple la 3FN.

La tabla EE tampoco alcanza la 3FN, ya que, si bien cumple 2FN, presenta dependencias transitivas, que son:

- **Departamento** depende de **Codigo_Departamento**, y **Codigo_Departamento** depende de **CUEANEXO**
- **Localidad** depende de **Codigo_Localidad**, y **Codigo_Localidad** depende de **CUEANEXO**

A modo de resumen, la tabla EE cumple 2FN y por ende 1FN, pero no 3FN. Mientras que la tabla EP cumple únicamente 1FN.

2.2 Calidad de los Datos

Se identificaron problemas de calidad distintos en las tablas originales de EE y EP.

El problema de calidad en la tabla de Establecimientos Educativos (EE) se debe a que el atributo "C. P." se encuentra vacío en algunos casos. El problema es de instancia, ya que se produce a partir de inconsistencias en los datos almacenados. Aplicando el modelo GQM de calidad de datos, se planteó lo siguiente:

- **Goal:** Evaluar la completitud del atributo "C.P."
- **Question:** ¿Cuál es el porcentaje de registros del padrón que no tienen un código postal cargado?

- **Metric:** Porcentaje de registros sin código postal

Se obtuvo que de 63662 registros, 2678 no cuentan con código postal, es decir, que el 4.21% de los registros no tienen código postal.

Diagnóstico: Este nivel de incompletitud podría afectarnos a la hora de hacer un join y podría complicar el cruce de datos con otras bases donde se tome como referencia el código postal.

Acción de mejora: Teniendo en cuenta que el código postal se calcula por localidad, dato que ya se tiene, se podría hacer una tabla que complete cada código postal según su localidad.

El problema de calidad que se encontró en la tabla de Establecimientos Productivos (EP) se debe a que la información sobre género se encuentra en filas separadas. Es decir, cada combinación de año, departamento y actividad económica aparece duplicada: una fila para “Varones” y otra para “Mujeres”. Este es un problema de modelo, ya que se origina en la estructura de la base de datos y no en los valores cargados. Para este análisis particular, se tomó únicamente los registros de 2022. Aplicando el modelo GQM de calidad de datos, se planteó lo siguiente:

- **Goal:** Evaluar si la representación del atributo “género” genera duplicación de registros para una misma combinación de año, departamento y actividad.
- **Question:** ¿Qué proporción de registros se repite por género en la tabla?
- **Metric:** Cantidad de registros duplicados por género

Se encontraron 61557 registros duplicados, lo cual equivale al 62,22% de los datos muestreados. **Diagnóstico:** Este diseño genera redundancia estructural, complica las consultas y produce casos donde solo se registra un género, afectando la completitud de la información.

Acción de mejora: Unificar la información en una sola fila por combinación de año, departamento y actividad, agregando columnas separadas para cada género.

2.3 DER y Modelo Relacional

Se generó un Diagrama Entidad-Relación (DER) que modela de manera conceptual solamente los datos que serán necesarios para cumplir el objetivo de este informe.




Figura 2.1. Diagrama Entidad-Relación (DER).

A partir del DER se definieron los esquemas correspondientes, todos se encuentran en 3FN. Tanto el DER como el Modelo Relacional fueron modelados en MIRO. El link para verlos en alta resolución se encuentra al pie de página.¹

¹ Miro




Figura 2.2. Modelo relacional con dependencias funcionales (DF), con respectivas Foreign Keys (FK) y Super Key (SK). Las claves primarias (PK) se notan subrayadas.

2.4 Descripción del proceso de importación de datos

Mediante los datasets originales brindados para el trabajo y un cuarto archivo llamado “[Actividades](#)” que aporta los códigos de actividad junto a su descripción, obtenida del Ministerio de Economía, se construyeron las tablas de la siguiente manera:

- Tabla dfProvincia: Del dataset Padrón de Establecimientos Productivos se extrajo el id y nombre de cada provincia
- Tabla dfPoblación: Del dataset Datos de población por Departamento, luego de unas modificaciones, se logró extraer nombre del departamento, edades del 0 al 110, población por edad e id de la provincia a la que pertenece el departamento. Combinando esta con la tabla departamento se consiguió cambiar el nombre del departamento por el id del mismo.
- Tabla dfDepartamento: Del dataset Padrón de Establecimientos Productivos se extrajo el ID del departamento, el nombre del mismo y el ID de la provincia a la que pertenece.
- Tabla dfEP_con_desc: Se combinó el dataset Padrón de Establecimientos Productivos con el dataset Actividades para formar una tabla que únicamente cuente con las actividades presentes en Padrón de Establecimientos Productivos. La misma presenta clae6 y su descripción
- Tabla dfEP: Del dataset Padrón de Establecimientos Productivos se extrajo 2 tablas, ambas compartían clae6, id del departamento al que pertenecen, cantidad de empresas exportadoras, empleados; se diferenciaban en el género de los empleados. Luego se juntaron ambas tablas en una con 2 columnas, una para trabajadores varones y otra para trabajadoras mujeres, y de clae6 se extrajo clae3, agregándole en otra columna.
- Tabla dfEE: Del código de localidad se puede extraer el ID de departamento en la mayoría de los casos, reemplazamos la columna de código de localidad por ID de departamento, solucionando a mano los casos específicos donde el código de localidad no contiene el ID de departamento. En el proceso eliminamos los departamentos que no están presentes en la tabla departamento y rellenamos los nulls con 0 para evitar futuros errores.

3. Decisiones tomadas

Para construir la tabla Establecimientos Educativos sólo se extrajo de la tabla original, los establecimientos de modalidad común, ya que las demás modalidades no se requirieron para ningún ejercicio. Para el ejercicio 1.I. y 2.II. del punto Análisis de datos. En el primero se pide explícitamente que sólo se tome en cuenta la modalidad común “(...) *la cantidad de Establecimientos Educativos (EE) de cada nivel educativo, considerando solamente la modalidad común...*”. En el segundo caso no se especifica la modalidad pero se asumió que era la común tras hablar con el ayudante de segunda de la materia.

Se asumieron los rangos etarios de la siguiente manera:

- Jardín maternal: 0 a 2 años
- Jardín de infantes: 3 a 5 años
- Primaria: 6 a 12 años
- Secundaria: 13 a 18 años
- SNU: 19 años o más

Por lo establecido en la ley 26.206 tomando una jurisdicción con 7 años de educación primaria y 5 años de educación secundaria. Además, se pensó en SNU como un nivel de educación superior. En los rangos etarios también se asume que los niveles educativos de secundario-INET y SNU-INET coinciden con los rangos etarios de secundario y SNU respectivamente.

En el dataset original “Padrón Oficial de Establecimientos Educativos del año 2022”, el código de departamento puede ser extraído del código de localidad. Una vez extraído el departamento Chascomús, aparece con código 6218. Mientras que en el dataset “Padrón de Establecimientos Productivos” aparece con el código 6217. Se asumió que ambos códigos se refieren al mismo departamento exacto (no simplemente a 2 departamentos distintos de igual nombre) y se tomó 6217 como el código de departamento de Chascomús correcto.

Solo se tuvieron en cuenta los departamentos presentes en el dataset original “Padrón de Establecimientos Productivos”, que son los que aparecen en la tabla modelo “dfDepartamento”.

En el ejercicio 1.iv. del apartado Análisis de datos para cada departamento se pide “(...) *los primeros tres dígitos del CLAE6 que más empleos genera...*” En caso de que haya 2 o más CLAE6 máximas en un departamento (que en un departamento 2 o más CLAE6 tengan el mismo número de empleados y a su vez tengan más empleados que cualquier otra actividad presente en el departamento), se elige cualquiera de estas de forma arbitraria.

En el ejercicio 2.v. del apartado Análisis de datos se pide “*Las 5 actividades (CLAE6) con mayor y menor proporción (respectivamente) de empleadas mujeres...*” no se tuvieron en cuenta actividades con nula presencia femenina.

4. Análisis de datos

4.1. Reportes

A partir del DER y el modelo relacional, se construyeron sus tablas en formato .CSV. La construcción de estos .CSV a partir de las tablas originales se encuentra en el archivo Tablas_Modelo.py.

Estas tablas modelos fueron utilizadas para generar los reportes solicitados utilizando solo consultas SQL. Los reportes se muestran a continuación pero pueden ser descargadas completas en formato .CSV al pie de la página.

Índice	provincia	departamento	Jardines	Poblacion Jardin	Primarios	Poblacion Primaria	Secundarios	Poblacion Secundaria	SNU	Poblacion Adultos
0	Buenos Aires	Luján	69	8352	49	12341	40	10388	10	79030
1	Buenos Aires	General La Madrid	21	866	16	1263	11	980	1	8426
2	Buenos Aires	Dolores	20	2569	22	3369	11	2998	4	22469
3	Buenos Aires	Punta Indio	16	936	14	1384	7	1047	1	8794
4	Buenos Aires	Cañuelas	34	6225	38	9538	33	7497	1	47282
5	Buenos Aires	San Antonio de Areco	34	2120	18	2873	12	2569	4	19133

Figura 4.1. Reporte 1.²

Índice	provincia	departamento	total
0	Buenos Aires	La Matanza	127962
1	Buenos Aires	Vicente López	120347
2	Buenos Aires	General Pueyrredón	118660
3	Buenos Aires	San Isidro	98372
4	Buenos Aires	La Plata	89699

Figura 4.2. Reporte 2.³

Índice	Provincia	Departamento	Cant_Expo_Mujeres	Cant_EE	Poblacion
0	Cordoba	Capital	1296	1327	1.49806e+06
1	Santa Fe	Rosario	1425	1130	1.33796e+06
2	Buenos Aires	La Matanza	864	1088	1.83717e+06
3	Buenos Aires	La Plata	233	756	756074
4	Entre Ríos	Paraná	275	672	388716

Figura 4.3. Reporte 3.⁴

Índice	Provincia	Departamento	CLAE3	Cant. empleos
0	CABA	Comuna 1	641	40247
1	CABA	Comuna 4	620	12598
2	CABA	Comuna 13	869	6528
3	CABA	Comuna 14	511	6363
4	Buenos Aires	Almirante Brown	851	4248

Figura 4.4. Reporte 4.⁵

² Archivo CSV: [Reporte 1](#)

³ Archivo CSV: [Reporte 2](#)

⁴ Archivo CSV: [Reporte 3](#)

⁵ Archivo CSV: [Reporte 4](#)

4.2. Reportes visuales. Gráficos.




Figura 4.5. Cantidad de empleos por provincia.

En la figura 4.5. se observa que la mayor concentración de empleos se da en las provincias más pobladas y de mayor actividad económica, principalmente Buenos Aires, Ciudad Autónoma de Buenos Aires, Santa Fe y Córdoba.




Figura 4.6. Relación entre población y cantidad de EE por nivel educativo x departamento.

En la figura 4.6 se observa una correlación positiva entre la cantidad de habitantes por departamento y la cantidad de establecimientos educativos en ese departamento. Se podría decir que a medida que aumenta la población, aumenta la cantidad de establecimientos educativos. También se aprecia una mayor densidad de primarios y secundarios.




Figura 4.7. Cantidad de establecimientos educativos ordenados de manera ascendente por la mediana de la provincia.

- Las cajas contienen el 50% de los departamentos en la provincia por cantidad de establecimientos educativos, según los departamentos de cada provincia.
- La línea dentro de cada caja representa la mediana.
- La línea vertical de cada caja representa la variación total dentro de cada provincia.
- Los puntos fuera de la caja y las líneas representan valores atípicos dentro de cada provincia.

En la figura 4.7 se observa que Buenos Aires, Santa Fe, Córdoba, Misiones y CABA presentan una mayor cantidad de establecimientos educativos con medianas superiores al resto. A partir de esto y la figura 4.5. parece posible concluir que hay una correlación positiva entre la cantidad de empleados de cada provincia y la cantidad de establecimientos educativos en esa provincia. Sin embargo, esto también se condice con la población total de las provincias, por lo que será necesario analizar gráficos como los siguientes en los que se muestran los establecimientos educativos y productivos en proporción a la cantidad de habitantes antes de sacar conclusiones.




Figura 4.8. Relación entre establecimientos educativos y trabajadores por cada 1000 habitantes por departamento.

En la figura 4.8 se observa lo que parecería ser un pico de empleados cada mil habitantes en 1 establecimiento educativo cada 1000 personas. Pagaría que un mayor número de establecimientos educativos no garantiza una mayor cantidad de empleo, incluso se puede ver una relación inversa a partir de 1 establecimiento educativo cada 1000 habitantes.




Figura 4.9. Porcentaje de mujeres en actividades productivas.

En la figura 4.9 se observa que las mujeres se concentran principalmente en servicios de cuidado de imagen y educación primaria, mientras que los sectores industriales o de transporte permanecen dominados por varones. El promedio (33,1%) muestra el porcentaje de mujeres empleadas en el total de actividades productivas.




Figura 4.10. Relación entre EE y trabajadores por cada 1000 habitantes por provincia.

Se realizó una tabla como la figura 4.8 pero por provincia en vez de por departamento. CABA parecería ser un caso particular con más de 500 empleados y aproximadamente 1 establecimiento educativo cada 1000 habitantes. Se concluyó que esto se debe a la inmensa cantidad de personas que trabajan en CABA pero residen en su periferia.

5. Conclusiones

Comenzamos este trabajo con la siguiente hipótesis: A mayor número de establecimientos educativos, habrá mayor número de empleados. Observando las figuras 4.5, 4.6 y 4.7 parecía que nuestras sospechas iban a ser corroboradas. Pero al avanzar con el trabajo pudimos observar que, si bien existe una relación entre establecimientos educativos y empleo, esta parece ser inversa si se mide de forma porcentual respecto a la población. En las figuras 4.8 y 4.10 se puede observar que a mayor número de establecimientos educativos, menor número de empleados (en estas figuras se toman ambos datos cada 1000 habitantes).

Creemos que esta relación inversa podría deberse a que los trabajos que requieren un menor nivel educativo suelen tener una mayor demanda de empleados frente a los más profesionalizados. Por lo que muchas personas que no tienen acceso a la educación o deciden abandonarla podrían ocupar esos puestos de trabajo. Esta falta de acceso a la educación podría deberse justamente a una escasez de establecimientos educativos, provocando que a menor número de establecimientos educativos las personas comiencen a trabajar en edades más tempranas.

Creemos que la práctica de los trabajos “pasados por generaciones”, trabajos que se enseñan informalmente (por ejemplo, entre familiares) sin necesidad de un establecimiento educativo de por medio, podría estar más presente en zonas rurales, con menor densidad de establecimientos educativos.

Creemos que la diferencia entre lo que percibimos en las primeras figuras y las últimas podría deberse simplemente a una centralización de los establecimientos educativos y del empleo en los lugares con mayor número de habitantes. En los departamentos con mayor población es normal que haya más cantidad de empleados nominalmente y que operen una mayor cantidad de establecimientos educativos.

Finalmente, creemos que si bien a mayor población se encuentran más empleados y establecimientos productivos de forma nominal, la relación entre la presencia de establecimientos educativos y empleados cada 1000 habitantes pareciera ser negativa, dando un mayor número de empleados a menor número de establecimientos educativos.

Para estudiar la hipótesis propuesta de por qué existe una correlación inversa entre empleo y establecimientos educativos, podríamos hacer una tabla que relacione qué rubros de empleo son más comunes en aquellos departamentos con menor presencia de establecimientos educativos. Sentimos que un análisis tan exhaustivo de la causa de esta problemática excede los objetivos del presente trabajo.

6. Fuentes y referencias

- **Repositorio GitHub:** <https://github.com/sofiaglionna/TP-LaboratorioDatos.git>
- **Establecimientos Educativos (EE):** Padrón Oficial de Establecimientos Educativos del año 2022. Disponible en: <https://www.argentina.gob.ar/educacion/evaluacion-e-informacion-educativa/padronoficial-de-establecimientos-educativos>
- **Establecimientos Productivos (EP):** Datos de establecimientos por departamento, actividad y género. Disponible en: <https://datos.produccion.gob.ar/dataset/distribucion-geografica-de-los-establecimientos-productivos/archivo/16f0dfc2-a9ff-4696-b2e5-79831c5c0ec4>
- **Población:** Datos de población por Departamento. <https://www.indec.gob.ar/indec/web/Nivel4-Tema-2-41-165>
- **Actividades:** Definición de cada actividad por su clae6. <https://datos.produccion.gob.ar/dataset/distribucion-geografica-de-los-establecimientos-productivos/archivo/d8ca32fa-a523-4583-96cc-97e4d21467aa>